

Introduction à la classification non-supervisée - Application à l'élection présidentielle 2017

```
library(tidyverse)
library(ggplot2)
```

Le but de ce TD est d'introduire la notion de classification non-supervisée, ou clustering. Il s'agit de classer n individus en groupes similaires en termes de caractéristiques. Des méthodes différentes existent, dont la classification hiérarchique, l'algorithme des k-moyennes ou l'algorithme EM. De même, les applications sont très nombreuses et incluent par exemple la classification de consommateurs aux profils d'achat similaires, la classification de cellules suivant les protéines qu'elles expriment ou la classification de données financières ou climatiques en séries temporelles de même profil.

Dans ce TD, nous nous intéresseront à la classification ascendante hiérarchique, ou CAH, et à l'algorithme des k-moyennes et les appliqueront à la classification des départements ou des circonscriptions suivant leur profil de vote au premier tour de l'élection présidentielle de 2017.

I. Clustering ascendant hiérarchique


Le principe d'un clustering hiérarchique est de partir d'une répartition en n groupes contenant chacun un unique élément et d'appliquer de façon récursive une procédure consistant à fusionner les deux groupes les plus proches. On obtient ainsi une suite de clusterings de toutes les tailles entre n et 1 parmi lesquels on peut choisir le plus pertinent.

Par exemple, considérons un ensemble de 5 individus (A, B, C, D, E) et que les étapes sont les suivantes:

- A et B sont les individus les plus proches: ils sont regroupés
- Parmi les quatre groupes restants, D et E sont les plus proches et sont groupés
- Parmi les trois groupes restants, C et (D, E) sont les plus proches et sont regroupés

- Il ne reste que deux groupes, qui sont fusionnés en un seul.

Cette exécution peut être résumée en un arbre de la façon suivante



En imaginant une ligne horizontale qui coupe cet arbre à différentes hauteurs, on retrouve toutes les classifications successives de l'algorithme. Ici, si on souhaite couper l'arbre à une hauteur où on obtient trois classes, on a bien la classification $\{(A, B), (C), (D, E)\}$.

La description précédente est très générale et s'applique à de nombreux types de données et de plusieurs façons. Pour appliquer une CAH en pratique, il faut préciser plusieurs paramètres:

- quelle est la distance (ou dissimilarité s'il ne s'agit pas d'une distance au sens mathématique du terme) qu'on considère entre les individus?
- comment élargit-on la notion de distance entre points à celle de dissimilarité entre groupes? On peut par exemple décider qu'il s'agit de la distance minimale entre éléments des deux groupes (méthode *single*), la distance maximale (*complete*), ou que les groupes les plus proches sont ceux dont la fusion augmente le moins la variance intra-groupes (*Ward*).
- comment choisir le bon nombre de groupes en lesquels séparer les données?

Classification des départements

1. Réaliser une CAH basée sur le nombre de votes (éventuellement les blancs et les abstentions mais pas les inscrits) par départements en utilisant la fonction *hclust*. Précisez les choix faits en termes de distance, même si ce sont ceux par défaut des fonctions utilisés. Où peut-on lire les classes des différents départements?
2. En lisant l'aide de *hclust*, tracer l'arbre associé à cette CAH. À quoi correspondent les hauteurs des branches? Commenter le résultat en termes de nombre de groupes, de département ayant un profil singulier (on parle d'*outlier*).

3. A l'aide de la fonction *cutree*, éliminer les outliers éventuels et séparer le restant en 2 groupes. Inspecter les départements du groupe le plus petit. A quoi semblent-ils correspondre? Peut-on le vérifier à l'aide des données? Ce clustering correspond-il à la question de la répartition suivant les profils de vote des départements? Dans les choix de paramètres que nous avons fait précédemment, quel est celui qui explique cette situation?
4. Proposer une façon de remédier à cela et reprendre la classification des départements. Que pouvez-vous dire des outliers? Limiter l'étude aux départements de France métropolitaine

Comparer des classifications

5. Reprendre cette classification en changeant le critère d'agrégation (ou de distance) entre les groupes, en remplaçant *complete* par *single* ou *Ward*. Les classifications obtenues avec le même nombre de groupes sont-elles les mêmes?

Une manière de voir si des classifications différentes sont tout de même similaires est d'utiliser un indicateur appelé *rand index* défini comme

$$RI = \frac{a + b}{\binom{n}{2}}$$

où a désigne le nombre de couples d'individus classés ensemble dans les deux classifications, et b le nombre de couples classés dans des classes différentes dans chacune des classifications. Plusieurs packages, dont *fossil* ont des fonctions permettant de calculer cet indice.

6. Quelle sont les bornes de RI et comment s'interprète-t-il? Déterminer les RI deux à deux des trois classifications obtenues. Vous semblent-elles comparables?

Algorithme des k-moyennes

Un autre moyen de réaliser une classification supervisée est *l'algorithme des k-moyennes* ou *k-means*.

Il consiste à choisir un nombre de K de classes, une distance d puis à réaliser l'algorithme suivant:

- A** Choisir K points de l'espace dans lequel sont les individus. Ces points sont appelés les centres et notés $C_1, \dots, C_k$.
- B** Créer K groupes $G_1, \dots, G_K$, un individu X étant assigné au groupe G_k tel que C_k est le centre le plus proche de X .

C Redéfinir les centres des k groupes créés comme

$$C_k = \underset{Y}{\operatorname{argmin}} \left\{ \sum_{X \in G_k} d(X, Y)^2 \right\}$$

D Reprendre les étapes B et C jusqu'à convergence, c'est-à-dire jusqu'à ce que les groupes ne se modifient plus.

Remarque: il peut arriver qu'un centre n'ait aucun individu rattaché à lui lors de l'étape B. Il est alors supprimé et le nombre de classes retenues diminue.

7. Dessiner un nuage de quelques points dans $\mathbb{R}^2$ et simuler une réalisation de l'algorithme en 3 groupes avec la distance euclidienne.
8. On note $C(X_i)$ le centre du groupe auquel est rattaché l'individu X_i et on définit (WSS pour *Within Sum of Squares*)

$$WSS = \sum_{i=1}^n d(X_i, C(X_i))^2$$

la somme des distances au carré entre les individus et leur centre le plus proche. Montrer que WSS ne fait que décroître au cours de l'exécution de l'algorithme. En déduire sa convergence.

Remarque: L'algorithme converge avec une décroissance permanente de WSS , mais rien ne garantit qu'il converge vers la classification ayant un SS minimal. En pratique, il y a une dépendance de la classification trouvée à la position initiale choisie. Il est recommandé de lancer plusieurs fois l'algorithme avec des initialisations différentes et de garder la meilleure solution trouvée.

9. Montrer que, dans le cas d'individus dans $\mathbb{R}^d$ muni de la distance euclidienne, la remise à jour de l'étape C correspond à prendre la moyenne des éléments du groupe.
10. Appliquer l'algorithme à l'aide de la fonction *kmeans* pour obtenir une classification des profils de vote. Pour cela, lancer l'algorithme pour plusieurs points de départ pour K compris entre 2 et 15. Garder en mémoire la valeur de WSS obtenue et tracer le graphe cette valeur en fonction de K . Une façon courante de choisir le nombre de classes est de garder celle correspondant le coude de cette fonction qui est en général décroissante. Comparer la classification obtenue aux classifications obtenues par CAH.

Classification hiérarchique des circonscriptions

11. Réaliser une classification hiérarchique des circonscriptions. Une fois la classification faite au niveau national, regarder quelle sont les classes des circonscriptions alsaciennes. Quelle interprétation peut-on en faire?